Emergência de Redes Livres de Escala com Agentes Semânticos baseados em Modelos de Decisão Sistema 1

Danilo Lindemberg Amorim

Plano de Pesquisa

Programa de Pós-Graduação em Modelagem em Sistemas Complexos

1 Introdução e Justificativa

O mecanismo clássico de explicação da emergência de redes livres de escala é a ligação preferencial de Barabási e Albert (1999), na qual o crescimento contínuo da rede combinado à probabilidade de conexão proporcional ao grau dos nós já existentes gera, de forma estocástica, uma topologia cuja distribuição de graus segue a Lei da Potência. Já foi observado, no entanto, que o comportamento livre de escala pode emergir de mecanismos formativos alternativos (CALDARELLI *et al.*, 2002; VÁZQUEZ, 2003; CANCHO; SOLÉ, 2003; D'SOUZA *et al.*, 2007; PAPADOPOULOS *et al.*, 2012).

A necessidade de entendimento dos mecanismos formativos subjacentes a este fenômeno motivou o desenvolvimento de modelos de simulação, que usualmente empregam a Modelagem Baseada em Agentes (ABM) (EPSTEIN, 1999; NAMATAME; CHEN, 2016; SKYRMS; PEMANTLE, 2000; ZIMMERMANN; EGUILUZ, 2005). Um recente desenvolvimento, a Modelagem Baseada em Agentes Generativos (GABM) (GHAFFARZADEGAN *et al.*, 2024), passou a utilizar Modelos Grandes de Linguagem (LLMs) como motor de decisão dos agentes na formação de redes complexas (MARZO; PIETRONERO; GARCIA, 2023; PIAO *et al.*, 2025; PAPACHRISTOU; YUAN, 2025; JI *et al.*, 2025b,a). Entre as justificativas apresentadas por adotantes da abordagem estão tornar os agentes mais críveis (PARK *et al.*, 2023; ADORNETTO *et al.*, 2025), dotá-los de senso comum e raciocínio contextual (VEZHNEVETS *et al.*, 2023), aproximá-los da racionalidade limitada humana, dotada de vieses e heurísticas, e flexibilizar regras de comportamento que de outra forma ficariam sujeitas ao viés do modelador (LU *et al.*, 2024; CHOPRA *et al.*, 2024; LAROOIJ; TÖRNBERG, 2025).

Todavia, os LLMs apresentam limitações que dificultam a simulação em larga escala e a validade externa dos experimentos neles baseados. Cada inferência é estocástica devido a amostragem de *tokens* de saída (ZHAO *et al.*, 2023; MINAEE *et al.*, 2024), além de apresentarem alto custo financeiro e latência de chamada (CHOPRA *et al.*, 2024; TAILLANDIER *et al.*, 2026). Como resultado, muitos estudos dependem de uma única execução (LAROOIJ; TÖRNBERG, 2025). Porém uma classe de modelos de IA pode suprir esta deficiência, os chamados Modelos de Decisão de Sistema 1 (DS1). O rótulo "Sistema 1"decorre da analogia com a decisão intuitiva descrita por Kahneman (2003) posteriormente formalizado na literatura de IA (BENGIO, 2019; BOOCH *et al.*, 2021;

GOYAL; BENGIO, 2022). O termo ganhou difusão comercial com o anúncio do modelo Jev (ALMEIDA, 2026), unificando um vocabulário antes disperso, sendo adotado pelos principais fornecedores (SRIVASTAVA, 2026; CLOUDFLARE, 2026; OPENAI, 2026), já apresentando recente reflexo na academia (SANTOS, 2026; DU *et al.*, 2026; AZIZI; POTRAGHLOO; PEDRAM, 2026).

Em vista disso, este trabalho propõe uma abordagem de Modelagem Baseada em Agente Semânticos (SABM) se apoiando em modelos DS1 como motor de decisão dos agentes. Investiga-se se essa abordagem é capaz de reproduzir as propriedades macroscópicas de redes livres de escala a partir de decisões microscópicas autônomas, e se seus resultados apresentam verossimilhança quando comparados aos modelos clássicos de formação de redes. O estudo se justifica por aplicar uma classe de modelos ainda pouco explorada em Sistemas Complexos e em ABM. A hipótese é de que o SABM atenda a grande parte das demandas que motivaram a GABM, porém, com custos computacionais, financeiros e temporais muito menores, além de habilitar a reprodutibilidade externa dos estudos. O laboratório de análise será a distribuição de popularidade (mensurada em "estrelas") de repositórios de projetos da rede sociotécnica do GitHub, que apresenta comportamento livre de escala.

2 Objetivos

O propósito deste trabalho é validar empiricamente a metodologia SABM como ferramenta para simular a emergência de redes livres de escala, comparando seus resultados com o mecanismo clássico de Barabási e Albert (1999) e identificando benefícios, limitações e oportunidades de aprimoramento. Os objetivos específicos são:

- Implementar e executar simulações de SABM reproduzindo o cenário de formação de redes de repositórios, em que a popularidade emerge de decisões microscópicas autônomas dos agentes desenvolvedores, os usuários da plataforma.
- Comparar quantitativamente as topologias simuladas com a topologia empírica, com o modelo Barabási-Albert e com mecanismos formativos alternativos, por meio da distribuição de grau, do coeficiente de agrupamento e do caminho médio.
- Investigar se a SABM reproduz a ligação preferencial linear ou se produz mecanismos emergentes distintos, como homofilia e otimização, que também convergem para a Lei da Potência.
- Avaliar criticamente os benefícios e custos da SABM em relação à ABM, à GABM e aos modelos clássicos, considerando escalabilidade computacional, interpretabilidade, determinismo, reprodutibilidade e transparência das decisões.

- Propor refinamentos e diretrizes metodológicas para o uso da SABM em simulações de formação de redes complexas, sustentados pelas evidências empíricas obtidas.

3 Revisão Bibliográfica

3.1 Redes complexas e mecanismos de formação

Esta seção sintetiza os modelos de redes complexas e os mecanismos propostos para explicar a formação de redes livres de escala, com base nas principais referências da ciência de redes (BARABÁSI, 2002; NEWMAN, 2010; LATORA; NICOSIA; RUSSO, 2017).

Uma rede é representável por um grafo, com nós interligados por arestas que definem interações (NEWMAN, 2003; WANG; CHEN, 2003). É dita complexa quando o comportamento coletivo não é previsível analisando apenas os componentes individuais, configurando emergência (MATA, 2020).

O ponto de partida do estudo das Redes Complexas é o modelo aleatório de Erdős e Rényi (1959), que substituiu o paradigma do estudo de grafos determinísticos vigente até então, pela análise estatística de espaços de grafos gerados por sorteios de arestas (BARABÁSI, 2002; LATORA; NICOSIA; RUSSO, 2017). Dadas conexões independentes e uniformes, os graus concentram-se próximos da média, e a formação do componente gigante exibe transição de fase no grau médio (ALBERT; BARABÁSI, 2002). Esses atributos fazem do modelo aleatório o referencial de mecanismos de formação, porque sem qualquer força motriz, não há razão para esperar qualquer heterogeneidade na rede (NEWMAN, 2003).

O modelo de pequeno mundo de Watts e Strogatz (1998) parte de uma rede regular, na qual cada nó se liga aos vizinhos mais próximos, e reconecta cada aresta com probabilidade p. Para $p = 0$, a rede permanece regular; para $p = 1$, torna-se aleatória. Em valores intermediários de p, a rede exibe caminhos médios curtos, típicos de grafos aleatórios, e alto agrupamento local, típico de redes regulares, com distribuição de grau ainda homogênea (LATORA; NICOSIA; RUSSO, 2017). Assim, o modelo delimita o regime no qual a conectividade eficiente coexiste com distribuição de grau igualitária.

Já o modelo livre de escala supõe distribuição de grau seguindo a Lei da Potência, a única função de densidade normalizável sob invariância a reescalonamento (ALBERT; BARABÁSI, 2002; NEWMAN, 2005), onde, $P(k) \sim k^{-\gamma}$. Nesse modelo, a ausência de escala típica e a assimetria de graus impõem a formação de *hubs*, nós com número extraordinário de conexões. Além disso, essas redes são descritas como robustas a falhas acidentais, porém frágeis diante de ataques direcionados aos *hubs* (NEWMAN, 2003; WANG; CHEN, 2003). O mecanismo formativo clássico é a ligação preferencial linear de Barabási e Albert (1999), na qual, em crescimento contínuo, cada novo nó cria m arestas cujo destino, o nó i, é sorteado pela probabilidade $\Pi(k_i) = k_i / \sum_j k_j$.

A combinação de crescimento e preferência proporcional ao grau reproduz distribuições com expoente em torno de $\gamma \approx 3$. A lei de crescimento do grau no tempo, $k_i(t) = m\left(\frac{t}{t_i}\right)^{1/2}$, formaliza a Vantagem do Pioneiro, pela qual o nó antigo acumula conexões de forma inevitável e nenhum recém-chegado o ultrapassa, independentemente de mérito (BARABÁSI; ALBERT; JEONG, 1999). As limitações do modelo são reconhecidas. A linearidade é um ponto de rigidez, pois no regime sublinear o modelo suprime os *hubs* e cai em decaimento exponencial, e no superlinear colapsa em monopólio, em que um único nó absorve quase todas as arestas novas (ALBERT; BARABÁSI, 2002). Além disso, o coeficiente de agrupamento do modelo tende a zero com o crescimento da rede, em dissonância com redes reais, nas quais ele permanece alto (NEWMAN, 2003).

A linhagem de correções desse modelo é conhecida. Price (1976), em trabalho predecessor, formalizou em redes de citações, dirigidas e acíclicas, a vantagem cumulativa do efeito Mateus, já conhecida na Sociologia (MERTON, 1968). O modelo Barabási-Albert é, em si, um caso especial não dirigido dessa formulação (NEWMAN, 2003). Posteriormente, Bianconi e Barabási (2001) introduzem a aptidão individual fixada no nascimento do nó, tornando a probabilidade de conexão proporcional ao produto $\eta_i k_i$. Dele emergem o multi-escalonamento e a Vantagem do mais Apto, sob a qual recém-chegados aptos superam antigos, embora a topologia final fique presa às hipóteses da distribuição de aptidão (BIANCONI; BARABÁSI, 2001). Este modelo também é criticado porque o cálculo de probabilidades pressupõe normalização global sobre o estado completo da rede, informação que um agente novo não possui (XU; ZHANG; ZHANG, 2010). Paralelamente, Holme e Kim (2002) acrescentam ao Barabási-Albert a formação controlada de tríades, estabilizando o coeficiente de agrupamento em valor finito ajustável enquanto preservam o expoente, também com o respaldo empírico em redes de colaboração científica (NEWMAN, 2003).

Uma vertente alternativa, no entanto, deixa os modelos estocásticos e se concentra em abordagens de otimização. D'Souza *et al.* (2007) demonstram que a preferencialidade pode emergir de minimização local de custos. No modelo de pedágio na fronteira, cada novo nó equilibra o custo dos saltos intermediários na rede com a profundidade topológica até a raiz, e a saturação dos nós mais centrais gera rede livre de escala com expoente $\gamma = 2$ e cauda exponencial, por isso rotulada temperada. Cancho e Solé (2003) partem da otimização global estática, equilibrando eficiência de comunicação e custo de conexões; entre o extremo de ligação aleatória e o extremo de ligação forçada, o ótimo do processo é uma rede truncada de Lei da Potência, com o grafo em estrela como exceção teórica e inviável. Tais resultados abalam a tese formativa até aqui exclusivamente estocástica, pois a mesma assinatura topológica pode derivar de critérios deliberados, sem crescimento de nós.

O debate sobre a adequação do rótulo "livre de escala" segue vivo. Newman (2003) admite desvios de cauda e defende o uso aproximativo do termo na prática. Já Broido e

Clauset (2019), ao analisar quase mil redes, verificam que distribuições alternativas, em particular a log-normal, retratam a maioria delas tão bem ou melhor do que a Lei da Potência. Todavia, propostas conciliadoras recentes mantêm o interesse em leis de cauda pesada (VOITALOV *et al.*, 2019; HOLME, 2019).

3.2 Modelagem Baseada em Agentes

A ABM representa o fenômeno por agentes individuais e suas interações (WILENSKY; RAND, 2015), e indaga como interações locais de agentes autônomos e heterogêneos geram regularidade macroscópica (EPSTEIN, 1999). Em contraste com a formulação de campo médio, que presume homogeneidade e substitui interações locais por interações uniformes de longo alcance, a ABM opera "de baixo para cima", lidando diretamente com indivíduos e com o caráter local das interações (BOCCARA, 2004).

Embora tenha sido inicialmente criticada pela suposta falta de rigor teórico (BOCCARA, 2004), adotantes dessa abordagem levantam argumentos a favor da sua robustez. Epstein (1999) demonstra que a simulação equivale formalmente a um ato de dedução lógico, pela tese de Church-Turing, enquanto Namatame e Chen (2016) se apoiam no princípio de irredutibilidade computacional de Wolfram (2002) para defender que sistemas sociais complexos frequentemente apresentam comportamento computacionalmente irredutível, acessível apenas pela execução passo a passo. No entanto, reproduzir uma regularidade não prova as regras geradoras, como advertido pelo princípio de equifinalidade de Bertalanffy (1977). É por isso que, nesse sentido, o modelador é aconselhado por Wilensky e Rand (2015) a submeter o modelo a validação rigorosa e testes de sensibilidade para distinguir padrões recorrentes de artefatos de calibragem.

As principais limitações da ABM concentram-se nas regras de decisão dos agentes. Regras condicionais rígidas do tipo "se-então", arbitrárias, formuladas com base na intuição pessoal do modelador, muito sensíveis a alteração, ou pouco adaptáveis, estão entre as principais críticas apontadas à ABM (CROOKS; HEPPENSTALL, 2011; ADORNETTO *et al.*, 2025; CHOPRA *et al.*, 2024; GAO *et al.*, 2023; LAROOIJ; TÖRNBERG, 2025; SCHULZE *et al.*, 2017). Soma-se a isso a dificuldade de codificar processos mentais, mantendo a parcimônia do modelo (NAMATAME; CHEN, 2016).

Nesse cenário, a GABM desponta como uma tentativa de preencher essa lacuna. Ela busca combinar a ABM tradicional com a IA Generativa ao se utilizar de um LLM como cérebro do agente. A premissa assumida é de que os LLMs possuem um conhecimento de mundo implícito e senso comum herdados do pré-treinamento em vastos corpos de dados humanos, o que permitiria substituir regras manuais rígidas por padrões comportamentais contextuais sociologicamente plausíveis, sem a necessidade de codificar cada reação individualmente (XI *et al.*, 2023; WANG *et al.*, 2023; ADORNETTO *et al.*, 2025; GHAFFARZADEGAN *et al.*, 2024). LLMs são modelos de redes neurais de arquitetura *Transformer* escalonados a bilhões de parâmetros (VASWANI *et al.*, 2017; ZHAO *et al.*,

2023), cuja interação por *prompts* dispensa ajuste fino para tarefas específicas sendo dotados de capacidades como aprendizado no contexto, cumprimento de instruções e raciocínio em múltiplas etapas (WEI *et al.*, 2022; ZHAO *et al.*, 2023). Todavia, trabalhos publicados sob esta abordagem ainda são duramente criticados pela comunidade científica em questões que variam de rigor metodológico até limitações inerentes aos LLMs. Muitos dos estudos dessa classe se apoiam em conclusões sobre a validade de face da simulação fazendo juízo subjetivo da credibilidade do comportamento do agente, sem evidenciar a validade empírica do mecanismo simulado. Motivos apontados para este cenário são a opacidade da "caixa-preta"do LLM, que dificulta interpretar, padronizar e replicar os resultados; a estocasticidade das saídas, que fragiliza o teste reprodutível; e os vieses sociais e de seleção herdados do *corpus* de treinamento, que caricaturam grupos humanos e induzem o modelo a reproduzir fenômenos já documentados na literatura, em vez de gerar a dinâmica que o modelador pretendia (LAROOIJ; TÖRNBERG, 2025; TAILLANDIER *et al.*, 2026). Não obstante, custo e latência elevados por decisão também se colocam com obstáculos à reprodutibilidade dos estudos (CHEN; ZAHARIA; ZOU, 2023). Nesse sentido, a seguir é apresentada uma classe de modelos que tem potencial para mitigar algumas das limitações da GABM.

3.3 Modelos de Decisão Sistema 1

A expressão "Sistema 1"tem raízes no trabalho de Kahneman (2003), que estruturou a decisão humana em dois regimes: o Sistema 1, intuitivo, rápido e automático, e o Sistema 2, deliberado e lento. Essa dualidade foi adotada na Inteligência Artificial como analogia para arquiteturas cognitivas (BENGIO, 2019; BOOCH *et al.*, 2021; GOYAL; BENGIO, 2022). De modo geral, a natureza autoregressiva da geração de tokens dos LLMs tende a apróximá-los do Sistema 1, mas alguns tipos de arquiteturas podem dotá-los de funções que os aproximam do Sistema 2 (BOOCH *et al.*, 2021; KAMBHAMPATI *et al.*, 2024; YAO *et al.*, 2023; SUMERS *et al.*, 2024). No entanto, essa taxonomia não é exclusiva dos LLMs, sua proposição original, feita por Bengio (2019), abrangia todas as famílias de modelos baseados em aprendizado profundo.

A adoção dos LLMs como cérebros de sistemas agênticos ocasionou a demanda por uma quantidade imprevista de decisões tipificadas em escala. Como a inferência dos LLMs é cara e de alta latência, pesquisadores desenvolveram modelos menores, como auxiliares para resolver as decisões nos primeiros estágios mais baratos e rápidos de arquiteturas em cascata (CHEN; ZAHARIA; ZOU, 2023). Nessa cascata, papéis como roteador (ONG *et al.*, 2025), triagem e assessor (NANDAKISHORE, 2026) aplicam o mesmo princípio de interpretar a entrada semântica e decidir de imediato, sem debate deliberado.

A classe dos Modelos de Decisão Sistema 1 engloba, no estágio atual, modelos de decisão primária de pequeno porte, com 1 a 4 bilhões de parâmetros, treinados para tarefas de decisão tipificada sobre entradas semânticas compactas e entregues sem amostragem

de tokens, com saída estável e rápida. Os exemplos comerciais marcam a classe, como o Jev, da TypeSafe AI (ALMEIDA, 2026), e o Laya (CONVAI INNOVATIONS, 2026), com adoção recente por outros fornecedores (SRIVASTAVA, 2026; CLOUDFLARE, 2026; OPENAI, 2026).

A nomenclatura unificou-se em torno do anúncio do Jev. Antes dele, a classe era referida por uma diversidade de termos, entre os quais roteador, triagem, assessor e primeiros estágios da cascata; depois dele, o rótulo DS1 foi adotado pelos fornecedores e começou a ser adotada também na literatura (DU *et al.*, 2026; SANTOS, 2026; AZIZI; POTRAGHLOO; PEDRAM, 2026). A fronteira da classe importa para este trabalho, pois o DS1 não é um LLM atuando como juiz nem um verificador de saídas, mas o elemento cognitivo de decisão inicial, cuja saída é aproveitável diretamente como ato do agente.

No modelo deste trabalho, cada atribuição de uma estrela é uma micro-decisão semântica de baixa complexidade e alta frequência, repetida por muitos desenvolvedores sobre muitos repositórios em cada passo temporal. O caso exige determinismo, custo baixo e rastreabilidade, requisitos típicos do DS1; frente ao LLM generativo da GABM, o DS1 troca julgamento conversacional por classificação de decisão, com menor riqueza contextual e reprodutibilidade externa de decisões. Essa troca está explícita na Metodologia.

3.4 GitHub como rede sociotécnica

O GitHub é uma das maiores plataformas de hospedagem e compartilhamento de código-fonte aberto do mundo (GITHUB, 2025; STACK OVERFLOW, 2025), na qual desenvolvedores compartilham projetos, conhecidos como repositórios, e colaboram de maneira organizada e segura. Para expressar apreciação por um repositório, o desenvolvedor pode atribuir a ele uma estrela, um mecanismo análogo à curtida em redes sociais, de modo que a quantidade de estrelas é uma proxy de popularidade consolidada na literatura (BORGES; HORA; VALENTE, 2016; BORGES; VALENTE, 2018; GU *et al.*, 2026).

A rede observável sobre essa plataforma é um grafo bipartido com desenvolvedores e repositórios nas duas partições, e arestas dirigidas de estrela. A distribuição de estrelas por repositório segue a Lei da Potência, com uma elite de repositórios concentrando dezenas de milhares de estrelas, enquanto a maioria permanece próxima de zero, configurando a desigualdade típica do efeito Mateus (BORGES; VALENTE, 2018; GU *et al.*, 2026; MERTON, 1968). O padrão de popularidade, contudo, não é mero somatório de mérito técnico individual, pois se forma no tempo, pelas decisões repetidas de milhares de desenvolvedores expostos a filas de descoberta com contagem visível, exatamente o processo cumulativo que a hipótese da ligação preferencial descreve e que este trabalho busca reproduzir decisão a decisão.

Argumenta-se, com Orlikowski e Scott (2008), que nessas plataformas a tecnologia e a prática social são mutuamente constitutivas, e por isso o GitHub é uma rede sociotécnica, e não um grafo técnico com interações humanas acessórias. No lado social do acoplamento

estão comunidades de uso, reputação, marketing técnico e círculos de divulgação; no lado técnico estão a adoção de linguagens e famílias tecnológicas, a infraestrutura de busca e ordenação, o README como superfície semântica de apresentação e os mecanismos de reutilização, como os forks (JIANG *et al.*, 2017). Evidências do acoplamento moldam o grafo, já que hubs centrais tornam-se alvo de ataques à cadeia de suprimento (SAAYMAN, 2026; DHOLAKIA; JAFFER, 2026), e sistemas de troca de estrelas, que fabricam ganho de popularidade, comprovam que a métrica é suscetível a manipulação social e, ao mesmo tempo, tecnicamente registrável (HE *et al.*, 2025).

O laboratório de dados decorre dessa caracterização, pois o GH Archive registra, de forma pública, granular e longitudinal, cada evento de estrela (GRIGORIK, s.d.), com metadados que descrevem linguagem, tópicos e conteúdo de apresentação do repositório. Isso permite verificar o conjunto de dados em recortes temporais bem delimitados e confrontar a simulação decidida por motor de decisão com a topologia real observada.

Por fim, a leitura sociotécnica alimenta diretamente o desenho da pesquisa, pois a dimensão social demanda que o agente carregue conteúdo semântico (temas de interesse, preferências de tecnologia, avaliação de documentação), e a dimensão técnica demanda que essa decisão seja determinística, logável e replicável, requisitos atendidos pelo DS1. Nesse enquadramento, o GitHub deixa de ser apenas um caso de estudo e se torna o referencial de verossimilhança para o modelo; se a emergência simulada reproduz o formato estatístico do fenômeno observado, a hipótese dos agentes semânticos ganha suporte; se revela mecanismos formativos distintos, o resultado enriquece o comparativo entre os mecanismos da seção 3.1.

4 Metodologia

A metodologia contempla simulação computacional com motor de decisão DS1, calibrada por dados empíricos do GitHub. O objeto observacional é um grafo bipartido, com desenvolvedores e repositórios públicos nas partições e arestas dirigidas de estrela emitidas ao longo do tempo; a popularidade dos repositórios, tomada como proxy de grau, é obtida pela projeção unipartida sobre os repositórios. A definição do grafo orienta as comparações seguintes, pois no Barabási-Albert as arestas nascem com o nó novo, enquanto as de estrela adicionam-se entre nós já existentes, com reativação repetida de pares, de modo que a comparação correta deve ser feita sobre a projeção unipartida, e não diretamente entre grafos de naturezas distintas.

O recorte de dados apoia-se em repositórios públicos criados entre janeiro de 2024 e abril de 2026, janela que acompanha cada repositório desde a criação e concentra o regime novo de contribuição assistida por LLMs (GU *et al.*, 2026; POPESCU *et al.*, 2026; TAILLANDIER *et al.*, 2026). São excluídos os repositórios vazios, os criados por bots, os nascidos de forks e os não-software, com a classificação por tipo conduzida pelo

próprio motor DS1 sobre o conteúdo do README, com precisão e recall relatados em amostra de validação (JIANG *et al.*, 2017; HE *et al.*, 2025). A atividade mínima de dois commits nos primeiros 30 dias é um limite de corte a ser testado em análise de sensibilidade, e os repositórios arquivados permanecem na análise, já que continuam a receber estrelas. Para eliminar o viés de sobrevivência, extrai-se a versão corrente do README em cada passo mensal, e os nomes e menções de repositórios são anonimizados, controlando a possibilidade de conhecimento prévio dos modelos sobre os repositórios, que podem integrar seus dados de treinamento.

O processo de coleta e simulação tem quatro fases. Na Fase I, extração, os eventos são coletados do GH Archive (GRIGORIK, s.d.) por consulta em plataforma de nuvem, baixados em arquivos Parquet locais e complementados pelos metadados dos repositórios e pelos READMEs versionados, coletados da API oficial do GitHub (GITHUB, 2025). Na Fase II, pós-processamento, os READMEs são vetorizados com jina-code-embeddings (KRYVOSHEIEVA *et al.*, 2025) em banco de dados vetorial indexado por passo mensal, e constrói-se a série temporal de temas de interesse a partir dos tópicos declarados pelos repositórios. Na Fase III, simulação, agentes com personas fundamentadas no perfil dos desenvolvedores (BORGES; VALENTE, 2018; STACK OVERFLOW, 2025) simulam a descoberta por similaridade semântica de temas, reordenam os resultados e os avaliam segundo o modelo de cascata (CRASWELL *et al.*, 2008); em seguida, o agente recebe o README completo do resultado escolhido e decide por estrela com o motor DS1 (Jebadiah 4B v2 local, quantização Q8, hash travado, temperatura 0 e seed fixa), escolha justificada por restrição de hardware, benchmark independente e medição própria em tarefa análoga de classificação, com 90,3

Na Fase IV, validação, os critérios são hierarquizados. No critério primário, referente ao comportamento de ligação preferencial dentro da simulação, registra-se o grau relativo do repositório no instante de cada estrela e calcula-se a probabilidade condicional P(conectar | grau relativo) na amostra de estrelas; seu alinhamento proporcional ao grau relativo valida a hipótese de que a ligação preferencial emerge da decisão semântica, e sua independência do grau refuta-a, indicando emergência por mecanismo distinto. Os critérios secundários reservam o peso da assinatura de escala ao teste estatístico formal, compreendendo o ajuste de Lei da Potência segundo Clauset, Shalizi e Newman (2009), o comparativo com alternativa log-normal (BROIDO; CLAUSET, 2019), o Kolmogorov-Smirnov como medida descritiva da distância entre distribuições e o teste de equivalência TOST com margem pré-registrada antes da execução. A análise de sensibilidade varia o número de agentes, o tamanho m da lista de descoberta e o corte de atividade mínima, de modo a garantir que a consistência não dependa de valores pontuais de hiperparâmetros.

Reprodutibilidade é tratada como parte da metodologia, não como anexo, e o protocolo de execução segue o ODD (Visão Geral, Conceitos de Desenho e Detalhes) (GRIMM *et al.*, 2006), com versão e hash do modelo travados, temperatura, seed, prompts versionados e

logs de decisão completos armazenados. Ainda antes da simulação em massa, o motor será submetido a teste de estabilidade, que repete decisões idênticas sob condições idênticas, repete-as com ordem embaralhada dos candidatos e com inversão dos pares apresentados, e mede a taxa de troca e a variação máxima de probabilidade. Esse teste protege o critério primário, pois, sem ele, a assinatura de ligação preferencial poderia herdar flutuações estocásticas do motor em lugar da decisão semântica.

Referências Bibliográficas

ADORNETTO, Carlo *et al.* Generative Agents in Agent-Based Modeling: Overview, Validation, and Emerging Challenges. **IEEE Transactions on Artificial Intelligence**, v. 6, n. 12, p. 3165–3183, 2025. DOI: 10.1109/TAI.2025.3566362. Disponível em: https://ieeexplore.ieee.org/document/10985773.

ALBERT, Réka; BARABÁSI, Albert-László. Statistical mechanics of complex networks. **Reviews of Modern Physics**, v. 74, n. 1, p. 47–97, 2002. DOI: 10.1103/RevModPhys.74.47. Disponível em: https://journals.aps.org/rmp/abstract/10.1103/RevModPhys.74.47. Acesso em: 14 maio 2026.

ALMEIDA, Diogo. **Introducing System One Models and Jev**. [*S. l.: s. n.*], 2026. Disponível em: https://typesafe.ai/blog/introducing-system-one-models-and-jev. Acesso em: 16 out. 2026.

AZIZI, Seyedarmin; POTRAGHLOO, Erfan Baghaei; PEDRAM, Massoud. **Labels Override Definitions in Jev-Style Typed Decision Models**. [*S. l.: s. n.*], 2026. arXiv: 2610.02586 [cs.AI]. Disponível em: https://arxiv.org/abs/2610.02586.

BARABÁSI, Albert-László. **Linked: the new science of networks**. Cambridge, MA: Perseus Publishing, 2002.

BARABÁSI, Albert-László; ALBERT, Réka. Emergence of Scaling in Random Networks. **Science**, v. 286, n. 5439, p. 509–512, 1999. DOI: 10.1126/science.286.5439.509. Disponível em: https://www.science.org/doi/10.1126/science.286.5439.509. Acesso em: 15 abr. 2026.

BARABÁSI, Albert-László; ALBERT, Réka; JEONG, Hawoong. Mean-field theory for scale-free random networks. **Physica A**, v. 272, n. 1-2, p. 173–187, 1999. DOI: 10.1016/S0378-4371(99)00291-5. Disponível em: https://www.sciencedirect.com/science/article/pii/S0378437199002915. Acesso em: 15 abr. 2026.

BENGIO, Yoshua. **From System 1 Deep Learning to System 2 Deep Learning**. [*S. l.: s. n.*], 2019. NeurIPS 2019 Invited Talk (Posner Lecture). Disponível em: https://neurips.cc/virtual/2019/invited-talk/15488. Acesso em: 15 out. 2026.

BERTALANFFY, Ludwig von. **Teoria Geral dos Sistemas**. Petrópolis: Vozes, 1977.

BIANCONI, Ginestra; BARABÁSI, Albert-László. Competition and multiscaling in evolving networks. **Europhysics Letters**, v. 54, n. 4, p. 436–441, 2001. DOI: 10.1209/epl/i2001-00260-6. Disponível em: https://doi.org/10.1209/epl/i2001-00260-6. Acesso em: 15 abr. 2026.

BOCCARA, Nino. **Modeling Complex Systems**. New York: Springer, 2004.

BOOCH, Grady *et al.* Thinking Fast and Slow in AI. *In:* 17. PROCEEDINGS of the AAAI Conference on Artificial Intelligence. [*S. l.: s. n.*], 2021. v. 35, p. 15042–15046. DOI: 10.1609/aaai.v35i17.17765. Disponível em: https://doi.org/10.1609/aaai.v35i17.17765. Acesso em: 15 out. 2026.

BORGES, Hudson; HORA, Andre; VALENTE, Marco Tulio. Predicting the Popularity of GitHub Repositories. *In:* INTERNATIONAL CONFERENCE ON PREDICTIVE MODELS AND DATA ANALYTICS IN SOFTWARE ENGINEERING. [*S. l.: s. n.*], 2016. Disponível em: https://arxiv.org/abs/1607.04342. Acesso em: 11 abr. 2026.

BORGES, Hudson; VALENTE, Marco Tulio. What's in a GitHub Star? Understanding Repository Starring Practices in a Social Coding Platform. **Journal of Systems and Software**, v. 146, p. 112–129, 2018. Disponível em: https://arxiv.org/abs/1811.07643. Acesso em: 11 abr. 2026.

BROIDO, Anna D.; CLAUSET, Aaron. Scale-free networks are rare. **Nature Communications**, v. 10, 2019. DOI: 10.1038/s41467-019-08746-5. Disponível em: https://www.nature.com/articles/s41467-019-08746-5. Acesso em: 15 abr. 2026.

CALDARELLI, Guido. *et al.* Scale-Free Networks from Varying Vertex Intrinsic Fitness. **Physical Review Letters**, v. 89, n. 25, 2002. DOI: 10.1103/PhysRevLett.89.258702. Disponível em: https://doi.org/10.1103/PhysRevLett.89.258702. Acesso em: 15 abr. 2026.

CANCHO, Ramon Ferrer i; SOLÉ, Ricard V. Optimization in Complex Networks. *In:* STATISTICAL Mechanics of Complex Networks. [*S. l.: s. n.*], 2003. v. 625, p. 114–126. DOI: 10.1007/978-3-540-44943-0_7. Disponível em: https://link.springer.com/chapter/10.1007/978-3-540-44943-0_7. Acesso em: 31 maio 2026.

CHEN, Lingjiao; ZAHARIA, Matei; ZOU, James. **FrugalGPT: How to Use Large Language Models While Reducing Cost and Improving Performance**. [*S. l.: s. n.*], 2023. DOI: 10.48550/arXiv.2305.05176. eprint: 2305.05176. Disponível em: https://arxiv.org/abs/2305.05176. Acesso em: 15 out. 2026.

CHOPRA, Ayush *et al.* **On the limits of agency in agent-based models**. [*S. l.: s. n.*], 2024. DOI: 10.48550/arXiv.2409.10568. eprint: 2409.10568. Disponível em: https://arxiv.org/abs/2409.10568.

CLAUSET, Aaron; SHALIZI, Cosma Rohilla; NEWMAN, Mark E. J. Power-law distributions in empirical data. **SIAM Review**, v. 51, n. 4, p. 661–703, 2009. DOI: 10.1137/070710111. Disponível em: https://arxiv.org/abs/0706.1062. Acesso em: 15 abr. 2026.

CLOUDFLARE. **Introducing Clef: Our Open-Source Decision Models, and New RL Fine-Tuning Platform**. [*S. l.: s. n.*], 2026. Disponível em: https://blog.cloudflare.com/clef-decision-models/. Acesso em: 16 out. 2026.

CONVAI INNOVATIONS. **Laya: Multilingual Non-Autoregressive System 1 Decision Model**. [*S. l.: s. n.*], 2026. Disponível em: https://huggingface.co/convaiinnovations/laya. Acesso em: 16 out. 2026.

CRASWELL, Nick *et al.* An experimental comparison of click position-bias models. *In:* INTERNATIONAL CONFERENCE ON WEB SEARCH AND DATA MINING. [*S. l.: s. n.*], 2008. p. 87–94. DOI: 10.1145/1341531.1341545. Disponível em: https://dl.acm.org/doi/10.1145/1341531.1341545. Acesso em: 15 abr. 2026.

CROOKS, Andrew T.; HEPPENSTALL, Alison J. **Introduction to Agent-Based Modelling**. [*S. l.*]: Agent-Based Models of Geographical Systems, 2011. DOI: 10.1007/978-90-481-8927-4_5. Disponível em: https://doi.org/10.1007/978-90-481-8927-4_5. Acesso em: 15 out. 2026.

D'SOUZA, Raissa M. *et al.* Emergence of tempered preferential attachment from optimization. **Proceedings of the National Academy of Sciences**, v. 104, n. 15, p. 6112–6117, 2007. DOI: 10.1073/pnas.0606779104. Disponível em: https://www.pnas.org/doi/10.1073/pnas.0606779104. Acesso em: 31 maio 2026.

DHOLAKIA, Krish; JAFFER, Ishaan. **Security update: March 2026 supply chain incident**. [*S. l.: s. n.*], 2026. Disponível em: https://docs.litellm.ai/blog/security-update-march-2026. Acesso em: 15 abr. 2026.

DU, Yanrui *et al.* **How Reliable Are System-One Decisions in Medicine? A Comparative Study of Jev, Jev-like Models, and LLMs**. [*S. l.: s. n.*], 2026. DOI: 10.48550/arXiv.2610.18529. arXiv: 2610.18529 [cs.CL]. Disponível em: https://arxiv.org/abs/2610.18529.

EPSTEIN, Joshua M. Agent-based computational models and generative social science. **Complexity**, v. 4, n. 5, p. 41–60, 1999. DOI: 10.1002/(SICI)1099-0526(199905/06)4:5<41::AID-CPLX9>3.0.CO;2-F. Disponível em: https://onlinelibrary.wiley.com/doi/10.1002/(SICI)1099-0526(199905/06)4:5%5C%3C41::AID-CPLX9%5C%3E3.0.CO;2-F. Acesso em: 4 jun. 2026.

ERDŐS, Paul; RÉNYI, Alfréd. On random graphs. **Publicationes Mathematicae**, v. 6, p. 290–297, 1959.

GAO, Chen *et al.* **Large language models empowered agent-based modeling and simulation: a survey and perspectives**. [*S. l.: s. n.*], 2023. eprint: 2312.11970v1. Disponível em: https://arxiv.org/abs/2312.11970. Acesso em: 4 jun. 2026.

GHAFFARZADEGAN, Navid *et al.* Generative agent-based modeling: an introduction and tutorial. **System Dynamics Review**, v. 40, n. 1, 2024. DOI: 10.1002/sdr.1761. Disponível em: https://doi.org/10.1002/sdr.1761. Acesso em: 15 abr. 2026.

GITHUB. **Octoverse: A new developer joins GitHub every second as AI leads TypeScript to #1**. [*S. l.: s. n.*], 2025. Disponível em: https://github.blog/news-insights/octoverse/octoverse-a-new-developer-joins-github-every-second-as-ai-leads-typescript-to-1/. Acesso em: 11 abr. 2026.

GOYAL, Anirudh; BENGIO, Yoshua. Inductive Biases for Deep Learning of Higher-Level Cognition. **Proceedings of the Royal Society A**, v. 478, n. 2266, p. 20210068, 2022. DOI: 10.1098/rspa.2021.0068. Disponível em: https://doi.org/10.1098/rspa.2021.0068. Acesso em: 15 out. 2026.

GRIGORIK, Ilya. **GH Archive**. [*S. l.: s. n.*], s.d. Disponível em: https://www.gharchive.org/. Acesso em: 11 abr. 2026.

GRIMM, Volker *et al.* A standard protocol for describing individual-based and agent-based models. **Ecological Modelling**, v. 198, n. 1-2, p. 115–126, 2006. DOI: 10.1016/j.ecolmodel.2006.04.023. Disponível em: https://www.sciencedirect.com/science/article/abs/pii/S0304380006002043. Acesso em: 17 set. 2026.

GU, Fei *et al.* **The Matthew Effect of AI Programming Assistants: A Hidden Bias in Software Evolution**. [*S. l.: s. n.*], 2026. eprint: 2509.23261v3. Disponível em: https://arxiv.org/abs/2509.23261v3. Acesso em: 11 abr. 2026.

HE, Hao *et al.* **Six Million (Suspected) Fake Stars in GitHub: A Growing Spiral of Popularity Contests, Spams, and Malware**. [*S. l.: s. n.*], 2025. eprint: 2412.13459v2. Disponível em: https://arxiv.org/abs/2412.13459v2. Acesso em: 11 abr. 2026.

HOLME, Petter. Rare and everywhere: Perspectives on scale-free networks. **Nature Communications**, v. 10, 2019. DOI: 10.1038/s41467-019-09038-8. Disponível em: https://www.nature.com/articles/s41467-019-09038-8. Acesso em: 15 abr. 2026.

HOLME, Petter; KIM, Beom Jun. Growing scale-free networks with tunable clustering. **Physical Review E**, v. 65, n. 2, 2002. DOI: 10.1103/PhysRevE.65.026107. Disponível em: https://journals.aps.org/pre/abstract/10.1103/PhysRevE.65.026107. Acesso em: 30 maio 2026.

JI, Jiarui *et al.* Leveraging LLM-based agents for social science research: insights from citation network simulations. **arXiv**, 2025. Disponível em: https://arxiv.org/abs/2511.03758. Acesso em: 4 jun. 2026.

JI, Jiarui *et al.* LLM-based multi-agent systems are scalable graph generative models. *In:* FINDINGS of the Association for Computational Linguistics. [*S. l.: s. n.*], 2025. p. 1492–1523. DOI: 10.18653/v1/2025.findings-acl.78. Disponível em: https://aclanthology.org/2025.findings-acl.78/. Acesso em: 4 jun. 2026.

JIANG, Jing *et al.* Why and how developers fork what from whom in GitHub. **Empirical Software Engineering**, v. 22, n. 1, p. 547–578, 2017. DOI: 10.1007/s10664-016-9436-6. Disponível em: https://link.springer.com/article/10.1007/s10664-016-9436-6. Acesso em: 11 abr. 2026.

KAHNEMAN, Daniel. A Perspective on Judgment and Choice: Mapping Bounded Rationality. **American Psychologist**, v. 58, n. 9, p. 697–720, 2003. DOI: 10.1037/0003-066X.58.9.697. Disponível em: https://psycnet.apa.org/record/2003-08746-001. Acesso em: 15 out. 2026.

KAMBHAMPATI *et al.* **LLMs Cant Plan But Can Help Planning in LLM-Modulo Frameworks**. [*S. l.: s. n.*], 2024. Acesso em: 15 out. 2026.

KRYVOSHEIEVA, Daria *et al.* **Efficient Code Embeddings from Code Generation Models**. [*S. l.: s. n.*], 2025. eprint: 2508.21290. Disponível em: https://arxiv.org/abs/2508.21290. Acesso em: 11 abr. 2026.

LAROOIJ, Maik; TÖRNBERG, Petter. Do large language models solve the problems of agent-based modeling? A critical review of generative social simulations. **arXiv**, 2025. Disponível em: https://arxiv.org/abs/2504.03274. Acesso em: 4 jun. 2026.

LATORA, Vito; NICOSIA, Vincenzo; RUSSO, Giovanni. Models of Growing Graphs. *In:* COMPLEX Networks: Principles, Methods and Applications. [*S. l.: s. n.*], 2017. p. 206–256. DOI: 10.1017/9781316216002.008. Acesso em: 15 abr. 2026.

LU, Yikang *et al.* LLMs and generative agent-based models for complex systems research. **Physics of Life Reviews**, v. 51, p. 283–293, 2024. DOI: 10.1016/j.plrev.2024.10.013. Disponível em: https://doi.org/10.1016/j.plrev.2024.10.013. Acesso em: 15 abr. 2026.

MARZO, Giordano De; PIETRONERO, Luciano; GARCIA, David. Emergence of scale-free networks in social interactions among large language models. **arXiv**, 2023. Disponível em: https://arxiv.org/abs/2312.06619. Acesso em: 3 jun. 2026.

MATA, Angélica Sousa da. Complex networks: a mini-review. **Brazilian Journal of Physics**, v. 50, p. 658–672, 2020. DOI: 10.1007/s13538-020-00772-9. Disponível em:

https://link.springer.com/article/10.1007/s13538-020-00772-9. Acesso em: 15 abr. 2026.

MERTON, Robert K. The Matthew Effect in Science. **Science**, v. 159, n. 3810, p. 56–63, 1968. DOI: 10.1126/science.159.3810.56. Disponível em: https://www.science.org/doi/10.1126/science.159.3810.56. Acesso em: 15 abr. 2026.

MINAEE, Shervin *et al.* **Large language models: a survey**. [*S. l.: s. n.*], 2024. DOI: 10.48550/arXiv.2402.06196. eprint: 2402.06196v3. Disponível em: https://arxiv.org/abs/2402.06196. Acesso em: 4 jul. 2026.

NAMATAME, Akira; CHEN, Shu-Heng. **Agent-based modeling and network dynamics**. Oxford: Oxford University Press, 2016. DOI: 10.1093/acprof:oso/9780198708285.001.0001. Disponível em: https://academic.oup.com/book/26751. Acesso em: 4 jun. 2026.

NANDAKISHORE, Gowthamkumar. **Laya as a Typed Probabilistic Assessor: An Independent Reproduction and a Preregistered Study of Calibration and Selective Escalation**. [*S. l.: s. n.*], 2026. arXiv: 2609.33843 [cs.AI]. Disponível em: https://arxiv.org/abs/2609.33843.

NEWMAN, Mark E. J. **Networks: an introduction**. Oxford: Oxford University Press, 2010. DOI: 10.1093/acprof:oso/9780199206650.001.0001. Disponível em: https://doi.org/10.1093/acprof:oso/9780199206650.001.0001. Acesso em: 15 abr. 2026.

NEWMAN, Mark E. J. Power laws, Pareto distributions and Zipf's law. **Contemporary Physics**, v. 46, n. 5, p. 323–351, 2005. DOI: 10.48550/arXiv.cond-mat/0412004. Disponível em: https://arxiv.org/abs/cond-mat/0412004. Acesso em: 2 maio 2026.

NEWMAN, Mark E. J. The structure and function of complex networks. **SIAM Review**, v. 45, n. 2, p. 167–256, 2003. DOI: 10.1137/S003614450342480. Disponível em: https://arxiv.org/abs/cond-mat/0303516v1. Acesso em: 15 abr. 2026.

ONG, Isaac *et al.* RouteLLM: Learning to Route LLMs with Preference Data. *In:* THE Thirteenth International Conference on Learning Representations. [*S. l.: s. n.*], 2025. DOI: 10.48550/arXiv.2406.18665. eprint: 2406.18665. Disponível em: https://arxiv.org/abs/2406.18665. Acesso em: 16 out. 2026.

OPENAI. **Decisions API Is Now Available in Public Beta**. [*S. l.: s. n.*], 2026. Disponível em: https://community.openai.com/t/decisions-api-is-now-available-in-public-beta/1403877. Acesso em: 16 out. 2026.

ORLIKOWSKI, Wanda J.; SCOTT, Susan V. Sociomateriality: Challenging the Separation of Technology, Work and Organization. **Academy of Management Annals**, v. 2, n. 1, p. 433–474, 2008. DOI: 10.1080/19416520802211444. Disponível em: https://doi.org/10.1080/19416520802211444. Acesso em: 19 out. 2026.

PAPACHRISTOU, Marios; YUAN, Yuan. Network formation and dynamics among multi-LLMs. **PNAS Nexus**, v. 4, n. 12, pgaf317, 2025. DOI: 10.1093/pnasnexus/pgaf317. Disponível em: https://academic.oup.com/pnasnexus/article/4/12/pgaf317/8361967. Acesso em: 4 jun. 2026.

PAPADOPOULOS, Fragkiskos *et al.* Popularity versus similarity in growing networks. **Nature**, v. 489, p. 537–540, 2012. DOI: 10.1038/nature11459. Disponível em: https://www.nature.com/articles/nature11459. Acesso em: 30 maio 2026.

PARK, Joon Sung *et al.* **Generative agents: interactive simulacra of human behavior**. [*S. l.: s. n.*], 2023. DOI: 10.48550/arXiv.2304.03442. eprint: 2304.03442v2. Disponível em: https://arxiv.org/abs/2304.03442. Acesso em: 4 jul. 2026.

PIAO, Jinghua *et al.* **Emergence of human-like polarization among large language model agents**. [*S. l.: s. n.*], 2025. eprint: 2501.05171v2. Disponível em: https://arxiv.org/abs/2501.05171. Acesso em: 3 jun. 2026.

POPESCU, Razvan Mihai *et al.* **Investigating Autonomous Agent Contributions in the Wild: Activity Patterns and Code Change over Time**. [*S. l.: s. n.*], 2026. eprint: 2604.00917v1. Disponível em: https://arxiv.org/abs/2604.00917v1. Acesso em: 11 abr. 2026.

PRICE, Derek De Solla. A general theory of bibliometric and other cumulative advantage processes. **Journal of the American Society for Information Science**, v. 27, n. 5, p. 292–306, 1976. DOI: 10.1002/asi.4630270505. Disponível em: https://asistdl.onlinelibrary.wiley.com/doi/abs/10.1002/asi.4630270505. Acesso em: 15 abr. 2026.

SAAYMAN, Jason. **Post Mortem: axios npm supply chain compromise**. [*S. l.: s. n.*], 2026. Disponível em: https://github.com/axios/axios/issues/10636. Acesso em: 15 abr. 2026.

SANTOS, Joas Antonio dos. **Calibrated Decision Models for Autonomous Penetration-Testing Harnesses: JEV and Laya as System One Decision Layers for LLM-Driven Pentest Agents**. [*S. l.: s. n.*], 2026. DOI: 10.48550/arXiv.2609.28940. eprint: 2609.28940. Disponível em: https://arxiv.org/abs/2609.28940. Acesso em: 16 out. 2026.

SCHULZE, Jule *et al.* Agent-Based Modelling of Social-Ecological Systems Achievements, Challenges, and a Way Forward. **Journal of Artificial Societies and Social Simulation**, v. 20, 2017. DOI: 10.18564/jasss.3423. Disponível em: https://doi.org/10.18564/jasss.3423. Acesso em: 15 out. 2026.

SKYRMS, Brian; PEMANTLE, Robin. A dynamic model of social network formation. **Proceedings of the National Academy of Sciences**, v. 97, n. 16, p. 9340–9346, 2000. DOI: 10.1073/pnas.97.16.9340. Disponível em: https://www.pnas.org/doi/10.1073/pnas.97.16.9340. Acesso em: 4 jun. 2026.

SRIVASTAVA, Achint. **Microsoft-Decision-1: Our Model for Fast Decision-Making**. [*S. l.: s. n.*], 2026. Disponível em: https://commandline.microsoft.com/microsoft-decision-1-model-foundry/. Acesso em: 16 out. 2026.

STACK OVERFLOW. **Stack Overflow Developer Survey 2025**. [*S. l.: s. n.*], 2025. Disponível em: https://survey.stackoverflow.co/2025. Acesso em: 11 abr. 2026.

SUMERS *et al.* **Cognitive Architectures for Language Agents**. [*S. l.: s. n.*], 2024. Acesso em: 15 out. 2026.

TAILLANDIER, Patrick *et al.* **Integrating LLM in Agent-Based Social Simulation: Opportunities and Challenges**. [*S. l.: s. n.*], 2026. eprint: 2507.19364v2. Disponível em: https://arxiv.org/abs/2507.19364. Acesso em: 11 abr. 2026.

VASWANI, A. *et al.* **Attention is all you need**. [*S. l.: s. n.*], 2017. eprint: 1706.03762. Disponível em: https://arxiv.org/abs/1706.03762. Acesso em: 18 set. 2026.

VÁZQUEZ, Alexei. Growing network with local rules: preferential attachment, clustering hierarchy, and degree correlations. **Physical Review E**, v. 67, n. 5, p. 056104, 2003. DOI: 10.1103/PhysRevE.67.056104. Disponível em: https://link.aps.org/doi/10.1103/PhysRevE.67.056104.

VEZHNEVETS, Alexander Sasha *et al.* **Generative agent-based modeling with actions grounded in physical, social, or digital space using Concordia**. [*S. l.: s. n.*], 2023. DOI: 10.48550/arxiv.2312.03664. eprint: 2312.03664. Disponível em: https://arxiv.org/abs/2312.03664. Acesso em: 11 abr. 2026.

VOITALOV, Ivan *et al.* Scale-free networks well done. **Physical Review Research**, v. 1, n. 3, 2019. DOI: 10.1103/PhysRevResearch.1.033034. Disponível em: https://journals.aps.org/prresearch/abstract/10.1103/PhysRevResearch.1.033034. Acesso em: 15 abr. 2026.

WANG, Lei *et al.* **A survey on large language model based autonomous agents**. [*S. l.: s. n.*], 2023. DOI: 10.48550/arXiv.2308.11432. eprint: 2308.11432v7. Disponível em: https://arxiv.org/abs/2308.11432. Acesso em: 4 jul. 2026.

WANG, Xiao Fan; CHEN, Guanrong. Complex networks: small-world, scale-free and beyond. **IEEE Circuits and Systems Magazine**, v. 3, n. 1, p. 6–20, 2003. DOI: 10.1109/MCAS.2003.1228503. Disponível em: https://ieeexplore.ieee.org/cdocument/1228503. Acesso em: 9 maio 2026.

WATTS, Duncan J.; STROGATZ, Steven H. Collective dynamics of 'small-world' networks. **Nature**, v. 393, p. 440–442, 1998. DOI: 10.1038/30918. Disponível em: https://www.nature.com/articles/30918. Acesso em: 15 abr. 2026.

WEI, Jason *et al.* Emergent Abilities of Large Language Models. **Transactions on Machine Learning Research**, 2022. Disponível em: https://openreview.net/forum?id=yzkSU5zdwD. Acesso em: 17 out. 2026.

WILENSKY, Uri; RAND, William. **An introduction to agent-based modeling**. Cambridge, MA: MIT Press, 2015. Disponível em: https://www.jstor.org/stable/j.ctt17kk851. Acesso em: 7 jun. 2026.

WOLFRAM, Stephen. **A new kind of science**. Champaign, IL: Wolfram Media, 2002. Disponível em: https://www.wolframscience.com/nks/. Acesso em: 15 jun. 2026.

XI, Zhiheng *et al.* **The rise and potential of large language model based agents: a survey**. [*S. l.: s. n.*], 2023. DOI: 10.48550/arXiv.2402.06196. Disponível em: https://arxiv.org/abs/2402.06196. Acesso em: 2 maio 2026.

XU, Xin-Jian; ZHANG, Liu-Ming; ZHANG, Li-Jie. **Mutual selection in network evolution: the role of the intrinsic fitness**. [*S. l.: s. n.*], 2010. DOI: 10.48550/arXiv.1002.1353. eprint: 1002.1353v1. Disponível em: https://arxiv.org/abs/1002.1353v1. Acesso em: 15 abr. 2026.

YAO, Shunyu *et al.* Tree of Thoughts Deliberate Problem Solving with Large Language Models. *In:* ADVANCES in Neural Information Processing Systems 36. [*S. l.: s. n.*], 2023. DOI: 10.52202/075280-0517. Disponível em: https://doi.org/10.52202/075280-0517. Acesso em: 15 out. 2026.

ZHAO, Wayne Xin *et al.* **A survey of large language models**. [*S. l.: s. n.*], 2023. DOI: 10.48550/arXiv.2303.18223. eprint: 2303.18223. Disponível em: https://arxiv.org/abs/2303.18223. Acesso em: 2 maio 2026.

ZIMMERMANN, Martín G.; EGUILUZ, Víctor M. Cooperation, social networks, and the emergence of leadership in a prisoner's dilemma with adaptive local interactions. **Physical Review E**, v. 72, n. 5, p. 056118, 2005. DOI: 10.1103/PhysRevE.72.056118. Disponível em:

https://journals.aps.org/pre/abstract/10.1103/PhysRevE.72.056118. Acesso em: 8 jun. 2026.